

证券研究报告 / 金融工程研究报告

指数门控在 LSTM 中的应用——eLSTM

---人工智能系列之四

报告摘要：

本篇报告主要介绍了深度学习神经网络 LSTM 的改进版本——eLSTM 模型的设计原理及性能表现。

在过往报告《扩展长短期记忆网络 xLSTM——人工智能系列之三》中介绍了 xLSTM 网络的原理并对其技术点进行了拆解。eLSTM 即从 xLSTM 中得到灵感，使用指数门控代替了传统 LSTM 模型的 Sigmoid 门控，并采取对输出的数值稳定性和指数门的数值稳定性进行了控制，最终得到了性能更优秀的 eLSTM 模型。

本报告设计了控制变量实验对 eLSTM 的性能进行测试，基准模型为 LSTM 模型和 GRU 模型。以全 A 股的日频量价数据作为训练数据集，分别以 eLSTM/LSTM/GRU 模型为基础构建了其余网络结构均相同的选股因子生成模型。在训练过程中，控制模型各项超参数与训练条件相同，并在全 A、沪深 300、中证 500、中证 1000 四个股票池中对三组因子进行了单因子测试。

测试结果表明：


(1) 在全 A 范围进行选股时，eLSTM 因子的多头组年化收益率 (18.24%) 以及超额年化收益率 (19.96%) 均大幅度领先 LSTM 因子 (多头 11.29% / 超额 12.90%) 和 GRU 因子 (多头 13.88% / 超额 15.53%)，控制回撤能力也相较于另外两组因子小优。eLSTM、LSTM、GRU 因子的超额最大回撤分别为 4.29%、5.24%、4.29%

(2) 在沪深 300、中证 500、中证 1000 成分股中进行选股，即在训练集的子集中进行选股时，eLSTM 因子的表现依旧较为稳健，相比于在全 A 选股的表现退步较小。而 LSTM 因子和 GRU 因子则在不同的股票池中均表现出了相对于在全 A 选股的较大退步。这表明 eLSTM 相比于基准模型能够更完整地提取出不同类型股票的关键信息。

以上两个结论能够证明改进后的 eLSTM 模型相对于 LSTM 模型具有明显的性能提升。同时 eLSTM 模型的性能相比于 GRU 模型也更优。

风险提示：本报告为模型能力探索，测试结果基于历史数据，存在模型失效风险。

eLSTM 因子分层回测图



相关报告

《适应市场状态与股票关联性的因子生成模型》

--20240904

《上月波动率、红利、流动性因子表现较优》

--20240903

《股票投资中的赔率/胜率/DCF 与 PB-ROE》

--20240902

《基于随机森林算法的信用风险识别模型》

--20240824

《沪深 300 好大高正，华安增强严快稳省》

--20240819

证券分析师：王琦

执业证书编号：S0550521100001

021-61002390 wangqi_5636@nesc.cn

目录

1.	引言	4
2.	指数门控长短期记忆网络-eLSTM	5
2.1.	LSTM 的局限性——长步信息遗失	5
2.2.	指数门控的 LSTM——eLSTM	9
3.	基于 eLSTM 构建选股模型	13
3.1.	数据集及预处理	13
3.2.	模型构建——基准模型及参数设置	14
3.3.	训练设置	15
4.	模型测试结果	16
4.1.	全 A（除北交所外）	16
4.2.	沪深 300 成分股	22
4.3.	中证 500 成分股	27
4.4.	中证 1000 成分股	33
5.	总结	39
6.	参考文献	39
7.	风险提示	39

图表目录

图 1: LSTM 网络示意图	6
图 2: LSTM 记忆遗失示意图	8
图 3: Sigmoid 函数和 exp 函数	9
图 4: 指数门控修复记忆示意图	10
图 5: eLSTM 网络示意图	11
图 6: 模型结构示意图	14
图 7: eLSTM 因子 IC 测试结果——全 A	16
图 8: eLSTM 因子 分层回测效果——全 A	17
图 9: LSTM 因子 IC 测试结果——全 A	18
图 10: LSTM 因子 分层回测效果——全 A	18
图 11: GRU 因子 IC 测试结果——全 A	19
图 12: GRU 因子 分层回测效果——全 A	20
图 13: 因子多头组对比——全 A	21
图 14: eLSTM 因子 IC 测试结果——沪深 300	22
图 15: eLSTM 因子 分层回测效果——沪深 300	22
图 16: LSTM 因子 IC 测试结果——沪深 300	23
图 17: LSTM 因子 分层回测效果——沪深 300	24
图 18: GRU 因子 IC 测试结果——沪深 300	25
图 19: GRU 因子 分层回测效果——沪深 300	25
图 20: 因子多头组对比——沪深 300	26
图 21: eLSTM 因子 IC 测试结果——中证 500	27
图 22: eLSTM 因子 分层回测效果——中证 500	28
图 23: LSTM 因子 IC 测试结果——中证 500	29
图 24: LSTM 因子 分层回测效果——中证 500	29
图 25: GRU 因子 IC 测试结果——中证 500	30
图 26: GRU 因子 分层回测效果——中证 500	31

图 27: 因子多头组对比——中证 500	32
图 28: eLSTM 因子 IC 测试结果——中证 1000.....	33
图 29: eLSTM 因子 分层回测效果——中证 1000.....	33
图 30: LSTM 因子 IC 测试结果——中证 1000	34
图 31: LSTM 因子分层回测效果——中证 1000.....	35
图 32: GRU 因子 IC 测试结果——中证 1000.....	36
图 33: GRU 因子 分层回测效果——中证 1000	36
图 34: 因子多头组对比——中证 1000	37

表 1: 模型参数设置	14
表 2: 训练参数及设置	15
表 3: eLSTM 因子业绩表现——全 A (2017.1-2024.7)	17
表 4: eLSTM 因子分年业绩表现——全 A (2017.1-2024.7)	17
表 5: LSTM 因子业绩表现——全 A (2017.1-2024.7)	19
表 6: LSTM 因子分年业绩表现——全 A (2017.1-2024.7)	19
表 7: GRU 因子业绩表现——全 A (2017.1-2024.7)	20
表 8: GRU 因子分年业绩表现——全 A (2017.1-2024.7)	20
表 9: 因子多头组、超额业绩表现对比——全 A (2017.1-2024.7)	21
表 10: eLSTM 因子业绩表现——沪深 300 (2017.1-2024.7)	23
表 11: eLSTM 因子分年业绩表现——沪深 300 (2017.1-2024.7)	23
表 12: LSTM 因子业绩表现——沪深 300 (2017.1-2024.7)	24
表 13: LSTM 因子分年业绩表现——沪深 300 (2017.1-2024.7)	24
表 14: GRU 因子业绩表现——沪深 300 (2017.1-2024.7)	26
表 15: GRU 因子分年业绩表现——沪深 300 (2017.1-2024.7)	26
表 16: 因子多头组业绩表现对比——沪深 300 (2017.1-2024.7)	27
表 17: eLSTM 因子业绩表现——中证 500 (2017.1-2024.7)	28
表 18: eLSTM 因子分年业绩表现——中证 500 (2017.1-2024.7)	28
表 19: LSTM 因子业绩表现——中证 500 (2017.1-2024.7)	30
表 20: LSTM 因子分年业绩表现——中证 500 (2017.1-2024.7)	30
表 21: GRU 因子业绩表现——中证 500 (2017.1-2024.7)	31
表 22: GRU 因子分年业绩表现——中证 500 (2017.1-2024.7)	31
表 23: 因子多头组业绩表现对比——中证 500 (2017.1-2024.7)	32
表 24: eLSTM 因子业绩表现——中证 1000 (2017.1-2024.7)	34
表 25: eLSTM 因子分年业绩表现——中证 1000 (2017.1-2024.7)	34
表 26: LSTM 因子业绩表现——中证 1000 (2017.1-2024.7)	35
表 27: LSTM 因子分年业绩表现——中证 1000 (2017.1-2024.7)	35
表 28: GRU 因子业绩表现——中证 1000 (2017.1-2024.7)	37
表 29: GRU 因子分年业绩表现——中证 1000 (2017.1-2024.7)	37
表 30: 因子多头组业绩表现对比——中证 1000 (2017.1-2024.7)	38

1. 引言

在多年以来的深度学习研究中，长短期记忆网络（LSTM）因其在处理序列数据中显示出的卓越性能而成为处理序列数据的主流选择。LSTM 具有优秀的记忆能力和有效的梯度传播机制，能够有效解决传统循环神经网络（RNN）面临的梯度消失问题，因此在自然语言处理、语音识别以及其他需要处理时间序列数据的领域中扮演了关键角色。随着技术的不断发展以及算力水平的提升，自然语言处理等领域的解决方案也是日新月异，Transformer、SSM、MoE 等大规模模型不断涌现，人工智能模型的表现突破了一个又一个高峰。

然而，近几年学界及业界的前沿研究资源多数都投入到大模型、多模态等通用人工智能研究方向。一切大模型的基础都是超大规模的训练语料库，只有足够规模的训练数据才能够支持大模型的预训练、微调，才能使深度学习模型性能达到通用语言任务甚至多模态任务的目标。而对于量化投资任务来说，高质量的训练数据规模还远远达不到大模型的训练要求。另一方面，金融序列数据的序列内部依赖与自然语言词元间的依赖具有不同的内部逻辑，Transformer 等大语言模型的基础架构并不能非常适配地直接用于量化投资问题。因此，在深度学习领域逐渐被大模型基础架构取代的 LSTM、GRU 等循环神经网络模型，仍然是深度学习量化投资方向上的主流选择。

近年的深度学习量化研究更多地集中在特征工程方面，而对提升模型本身性能的尝试相对并不多，本报告从扩展的长短期记忆网络（Extended Long Short-Term Memory, xLSTM）得到灵感，对 LSTM 模型进行了改进，使用指数门控（Exponential Gating）代替了传统 LSTM 模型的 Sigmoid 门控，eLSTM 模型在原理和测试结果上均大幅度提高了 LSTM 模型的序列特征提取能力。

本篇报告介绍 eLSTM 模型的理论原理和性能表现。eLSTM 模型通过指数门控解决了 LSTM 模型的长步信息遗失问题，模型通过序列数据进行建模的能力更进一步。本报告第二章介绍 eLSTM 模型的原理和改进逻辑。本报告第三、四章展示了 eLSTM 模型在使用 A 股历史量价数据进行选股因子挖掘上的能力。结果表明，在特征处理、超参数设置、初始化、训练参数等各方面均相同的条件下，eLSTM 模型具有远超 LSTM 和 GRU 的建模能力。

2. 指数门控长短期记忆网络-eLSTM

LSTM 的设计是为了解决传统 RNN 存在的缺陷。传统的 RNN 在训练过程中容易遇到梯度消失或梯度爆炸的问题，尤其是在处理长序列数据时。这是因为在反向传播过程中，梯度可能会随着时间步的增加而指数级减小（消失）或增大（爆炸）。这使得 RNN 难以学习和保持长期依赖关系。LSTM 通过引入一个复杂的门控机制，能够在不同时间点有选择性地添加或删除信息到记忆单元中，从而维持长期的信息流并避免梯度问题。

随着技术的发展，传统的 LSTM 已经逐渐跟不上当下日益增长的需求，要想不被时代所淘汰，势必要向 LSTM 中引入新的技术。LSTM 的原作者团队于 2024 年 5 月发布了《xLSTM: Extended Long Short-Term Memory》，将 LSTM 模型改进为用于大模型版本。有关 xLSTM 模型的技术原理拆解已经在早先发布的报告中做了比较详尽的介绍，具体内容可参见相关报告《扩展长短期记忆网络 xLSTM——人工智能系列之三》。对 xLSTM 进行原理拆解和分析，并与金融序列数据的特点进行匹配，我们认为将指数门控应用于 LSTM 的改进方案中是最符合逻辑的。

LSTM 通过输入门、遗忘门、输出门对学习到的信息进行存储、更新和输出的控制。传统 LSTM 的门控均采用 Sigmoid 函数来控制信息通过的比例，这会导致当输入序列较长时，较早的输入随着时间步的推移，保留比例逐渐减少甚至消失。而指数门控则是将输入门、遗忘门的控制函数改为指数函数，将门的值域从 $(0,1)$ 扩大到了 $(0,+\infty)$ ，从而更加灵活地控制过去记忆保留与当前记忆输入的混合比例。


本章节详细介绍 eLSTM 模型的设计动机、技术原理。关于 eLSTM 的灵感来源，有关 xLSTM 模型的技术原理拆解已经在早先发布的报告中做了比较详尽的介绍，具体内容可参见相关报告《扩展长短期记忆网络 xLSTM——人工智能系列之三》。限于篇幅，本节仅对 eLSTM 模型进行详细介绍。

2.1. LSTM 的局限性——长步信息遗失

2.1.1. LSTM 的基本原理

LSTM 的核心思想是引入一种特殊的内部状态机制——记忆单元（memory cell）来管理隐状态中记录的信息，通过几个门结构对其进行控制：输出门（output gate）用来从单元中输出条目；输入门（input gate）用于控制数据的读入；遗忘门（forget gate）用于重置记忆单元的内容。这三种门结构相配合的机制可以决定什么时候该对隐状态输入的信息作记忆，什么时候忽略过期的隐状态信息。同为隐藏层的输出，记忆单元仅用于网络内部信息的维护，隐状态则会传递到输出层用于预测当前时间步的输出结果。

图 1：LSTM 网络示意图



数据来源：东北证券

图 1 展示了 LSTM 模型的网络及隐藏层结构。LSTM 模型中的门均为取值范围为 (0,1) 的矩阵，代表输入的数据通过门之后保留的比例，因此选择 sigmoid 函数作为全连接层的激活函数。候选记忆 $\tilde{C}_t$ 则为了保持其值的范围与记忆单元 C_t 以及隐状态 H_t 相同，使用 tanh 函数作为全连接层的激活函数。这四种参数的计算方式相同。

$$\begin{aligned} I_t &= \sigma(X_t W_{xi} + H_{t-1} W_{hi} + b_i) \\ F_t &= \sigma(X_t W_{xf} + H_{t-1} W_{hf} + b_f) \\ O_t &= \sigma(X_t W_{xo} + H_{t-1} W_{ho} + b_o) \\ \tilde{C}_t &= \tanh(X_t W_{xc} + H_{t-1} W_{hc} + b_c) \end{aligned}$$

其中, W_{xi} , W_{xf} , W_{xo} , W_{xc} , W_{hi} , W_{hf} , W_{ho} , W_{hc} 为权重参数, b_i , b_f , b_o , b_c 是偏置参数。

记忆单元 C_t 的值由输入门 I_t 和遗忘门 F_t 进行控制, 其中输入门控制新时间步的数据加入记忆单元的比例, 捕获序列中的短期信息; 遗忘门则控制旧时间步的记忆单元中数据保留的比例, 捕获序列中的长期信息。记忆单元 C_t 的计算方法如下:

$$C_t = F_t \odot C_{t-1} + I_t \odot \tilde{C}_t$$

其中, 符号 “ $\odot$ ” 为哈达玛积运算, 含义为两个维度相同的矩阵按元素相乘得到新的矩阵。

输出门 O_t 则控制着记忆元 C_t 中的信息输出至隐状态 H_t 的比例:

$$H_t = O_t \odot \tanh(C_t)$$

如此得到的隐状态 H_t 相比于 RNN 中的隐状态, 增加了可学习的历史数据信息权重。LSTM 之所以能够克服 RNN 的缺陷, 是因为它特殊的结构使得在训练时总是可以通过选择合适的参数, 来避免梯度更新过程中的指数项带来梯度消失和梯度爆炸问题。

2.1.2. LSTM 的长步信息遗失问题

LSTM 的门控是一个非常具有开创性的设计, 但随着模型需要处理的任务越发复杂, 需要接收的输入序列也越来越长, 传统的 LSTM 暴露出了长步信息遗失的缺陷。

循环神经网络的长步信息遗失是指: 当输入序列较长时, 隐变量中携带的记忆随着时间步的推移不断被新的输入所挤占, 最终完全消失的现象。从理论上来说, 更长的序列所携带的依赖关系相较于短序列更多, 因此增加输入序列的长度应该使模型预测的准确率更高, 表现更好。但循环神经网络存在两方面的问题, 无法使用更长的输入序列获得更好的模型性能: 一是循环神经网络沿时间反向传播 (Back-Propagation Through Time, BPTT) 的过程中, 如果序列长度较大, 极易发生梯度爆炸或梯度消失问题, 导致训练无法正确进行, 因为不得不使用梯度裁剪等手段以及对序列长度进行控制, 来优先保证模型能正常训练、收敛。二就是长步信息遗失, 序列早期的信息传递到最新时间步时已经所剩无几, 对于模型预测的帮助聊胜于无。


LSTM 的提出便是为了缓解 RNN 模型的以上两个问题: 序列早期的信息能够存储在隐变量之外的记忆细胞中, 能够更好地对早期记忆进行存储; 门控则能够起到控制梯度范围的效果, 缓解梯度爆炸和梯度消失问题。因此, LSTM 在长序列问题上的处理能力相较于 RNN 有了很大的提升。

LSTM 相对于 RNN 的提升终究是有限的，并不能完全解决 RNN 的长步信息遗失问题。LSTM 的记忆单元也会和隐状态一样随着时间步的前进不断更新，早期记忆的权重不断减少。传统 LSTM 的 Sigmoid 门控值域为(0,1)的特性就导致了，模型只会对过去的记忆做减法，不会做加法。下式中， C_{t-1} 代表过去的记忆， $\tilde{C}_t$ 代表当前时间步获取的新记忆， F_t 和 I_t 是值域为(0,1)的门控，代表两种记忆保留的比例，相加后得到 C_t ，取代 C_{t-1} 存储在记忆单元中。

$$C_t = F_t \odot C_{t-1} + I_t \odot \tilde{C}_t$$

而在训练过程中一旦产生了“早期记忆对当前时间步的预测结果不重要”的决策，即某一时间步的 F_t 为较小值， C_{t-1} 在 C_t 中的权重就变得极低。即便最终的预测结果实际上是需要早期信息作为重要依据的，也无法再更改中间过程的决策了。图二比较直观的体现了记忆遗失的过程。

图 2：LSTM 记忆遗失示意图



数据来源：东北证券

那么反过来说，如果有一种机制能够在训练过程中修改过去做出的记忆舍弃决策，解决 LSTM 的长步记忆遗失问题，则可以使 LSTM 模型的长序列处理能力得到进一步的增强。eLSTM 模型就是通过使用指数函数代替 Sigmoid 函数作为输入门和遗忘门的激活函数来达成上述目标的。

2.2. 指数门控的 LSTM——eLSTM


2.2.1. Sigmoid 函数与指数函数

如上一节所述，LSTM 记忆存储的核心公式为下式：

$$C_t = F_t \odot C_{t-1} + I_t \odot \tilde{C}_t$$

而 F_t 、 I_t 两道门控的值域和分布则决定了记忆混合的方式。Sigmoid 和 $\exp$ 两种函数的图像如图 3 所示：

图 3：Sigmoid 函数和 $\exp$ 函数




数据来源：东北证券

Sigmoid 函数的曲线平滑，对于小范围的输入变化响应较小，这种特性有助于减少噪声和异常值对模型性能的影响，但在另一方面会导致记忆单元更新时，调整记忆混合比例更困难。

Exp 函数在定义域为正的区间增长迅速，能够通过大幅提高 C_{t-1} 和 $\tilde{C}_t$ 中某一项的权重，来达到调整记忆混合比例的目标，同时在定义域为负的区间变动很小，能够保证另一项记忆也有留存。整体来说， $\exp$ 函数能够提供更加灵活的记忆混合模式，以及修正过去决策的能力，如图 4 所示。但变动过于剧烈的正区间需要采用一定的手段来稳定数值，避免数值爆炸问题。

图 4：指数门控修复记忆示意图



数据来源：东北证券

2.2.2. eLSTM 网络的结构

eLSTM 的网络组织结构与 LSTM 相同，仅改变隐藏层的计算过程，计算过程进行了修改的部分使用异色进行标注：

$$\begin{aligned}
 I_t &= \exp(X_t W_{xi} + H_{t-1} W_{hi} + b_i) \\
 F_t &= \exp(X_t W_{xf} + H_{t-1} W_{hf} + b_f) \\
 O_t &= \sigma(X_t W_{xo} + H_{t-1} W_{ho} + b_o) \\
 \tilde{C}_t &= \tanh(X_t W_{xc} + H_{t-1} W_{hc} + b_c) \\
 C_t &= F_t \odot C_{t-1} + I_t \odot \tilde{C}_t
 \end{aligned}$$


输入门、遗忘门的激活函数由 Sigmoid 换成 Exp 函数，输出门、候选记忆单元以及记忆单元的计算过程不变。

由于指数门控的变动速度极快，eLSTM 的记忆单元 C_t 存储的值会落在更大的数值范围内，变动幅度也更大。因此，为了后续网络的稳定性，引入了标准器 N_t 来缩小隐状态 H_t 的变动幅度，稳定数值范围。 N_t 的初始化方式与 C_t 相同，更新过程也与 C_t 相似，因此每个时间步更新后的 C_t 与 N_t 相除后能够保持较小的变动幅度。

$$\begin{aligned}
 N_t &= F_t \odot N_{t-1} + I_t \\
 H_t &= O_t \odot (C_t / N_t)
 \end{aligned}$$

eLSTM 的网络结构示意图如下图 5 所示，其中与 LSTM 不同的运算单元用异色标出，引入标准器后与 N_t 相关的计算过程用虚线表示：

图 5: eLSTM 网络示意图



数据来源: 东北证券

2.2.3. eLSTM 的数值稳定方法

由于指数门对自变量的敏感程度极高，如果不对其稳定性加以控制，训练中容易发生数值溢出的稳定性问题，因此需要对指数门的计算过程进行稳定性优化。引入稳定器 M_t 来稳定指数门的数值范围：

$$M_t = (\log(F_t) + M_{t-1}, \log(I_t))$$

并使用稳定版本的输入门 I'_t 和遗忘门 F'_t 传递到下一个时间步：

$$\begin{aligned} I'_t &= \exp(\log(I_t) - M_t) \\ F'_t &= \exp(\log(F_t) + M_{t-1} - M_t) \end{aligned}$$

稳定状态 M_t 没有梯度，因此不会对其他梯度的计算造成影响，下面对稳定版本的输入门 I'_t 和遗忘门 F'_t 与 I_t 和 F_t 在前向传播中的等价性进行证明：

对稳定记忆单元 $C_t^{(s)}$ 与标准器 $N_t^{(s)}$ 做如下定义：

$$\begin{aligned} C_t &= C_t^{(s)} \exp(M_t) \\ N_t &= N_t^{(s)} \exp(M_t) \end{aligned}$$

在前向传播中：

$$\begin{aligned} \frac{C_t^{(s)}}{N_t^{(s)}} &= \frac{F'_t \odot C_{t-1}^{(s)} + I'_t \odot \tilde{C}_t}{F'_t \odot N_{t-1}^{(s)} + I'_t} \\ &= \frac{\exp(\log(F_t) + M_{t-1} - M_t) \odot C_{t-1}^{(s)} + \exp(\log(I_t) - M_t) \odot \tilde{C}_t}{\exp(\log(F_t) + M_{t-1} - M_t) \odot N_{t-1}^{(s)} + \exp(\log(I_t) - M_t)} \\ &= \frac{\exp(\log(F_t) + M_{t-1}) \odot C_{t-1}^{(s)} + \exp(\log(I_t)) \odot \tilde{C}_t}{\exp(\log(F_t) + M_{t-1}) \odot N_{t-1}^{(s)} + \exp(\log(I_t))} \\ &= \frac{\exp(\log(F_t)) \odot C_{t-1} + \exp(\log(I_t)) \odot \tilde{C}_t}{\exp(\log(F_t)) \odot N_{t-1} + \exp(\log(I_t))} \\ &= \frac{F_t \odot C_{t-1} + I_t \odot \tilde{C}_t}{F_t \odot N_{t-1} + I_t} = \frac{C_t}{N_t} = \tilde{H}_t \end{aligned}$$

因此，损失计算仅依赖于隐状态 H_t ，而不依赖于稳定器 M_t ， M_t 不存在梯度，仅用于稳定指数函数的数值。

3. 基于 eLSTM 构建选股模型

本章通过构建选股因子挖掘模型，对比在数据预处理、模型和训练参数设置等各种条件相同的前提下，eLSTM 与基准模型的表现差异，以论证 eLSTM 在建模能力上的优越性。

本章依次介绍实验各流程的设计方案，包括数据采样、数据集划分、数据预处理、网络结构搭建、模型参数设置以及训练参数设置。

3.1. 数据集及预处理

(1) 股票池：

2012 年至今全 A 股（除北交所外）日频量价数据。

(2) 样本输入：

单支股票基准日 t 前推 60 个连续交易日（包括基准日）的量价数据序列，每天包括 6 个特征：开盘价、最高价、最低价、收盘价、成交均价、成交量。依次组成的 $[60 \times 6]$ 的序列作为一个样本的输入。

(3) 样本标签：

单支股票基准日 t 后推 10 个交易日相对全 A 的超额收益作为一个样本的标签。超额收益的计算以 $t+2$ 日成交均价作为买入价格，以 $t+10$ 日成交均价作为卖出价格，计算公式如下：

$$label = \frac{stock_vwap_{t+10} * index_close_{t+2}}{stock_vwap_{t+2} * index_close_{t+10}} - 1$$

(4) 采样方法及数据清洗

以每个交易日作为基准日，按照 (2)、(3) 中的方式进行样本输入与标签的提取，将（输入，标签）数据完整，即形状为 $([60 \times 6], [1])$ 且不含空值的样本视为有效样本，舍弃无效样本。

(5) 数据集划分：

以 6 年基准日提取出的样本作为一个数据集，其中前 4 年的样本作为训练集，第 5 年作为验证集，第 6 年作为测试集。各数据集之间的时间跨度为 1 年，共 8 个数据集，最终生成 2017 至 2024 共 8 个年份的因子。

(6) 数据预处理：

样本的输入预处理：

在样本内进行，对每个样本的特征 $([60, 1])$ 分别进行时序上的 Z-Score 标准化。并舍去标准化后序列中包含 nan 和 inf 的样本。

样本的标签预处理：

在数据集内进行（训练集、验证集、测试集分开处理），对单个数据集内的全部标签统一进行 Z-Score 标准化。


标准化公式：

$$x_{standardized} = \frac{x - mean(x)}{std(x)}$$

3.2. 模型构建——基准模型及参数设置

以基本的 RNN 网络架构构建因子生成模型，包括 RNN 层、LayerNorm 层、Dropout 层和 Linear 层，其中 RNN 层为 eLSTM/LSTM/GRU 中之一，如下图所示：

图 6：模型结构示意图



数据来源：东北证券

模型各层的参数设置如下表 1：

表 1：模型参数设置

子层	参数	eLSTM	LSTM	GRU
RNN 层	input_size	6	6	6
	hidden_size	64	64	64
	num_layers	1	1	1
Dropout	dropout	0.3	0.3	0.3
Linear 层	input_size	64	64	64
	output_size	1	1	1

数据来源：东北证券

3.3. 训练设置

测试区间为 2017-2024 年，每年训练一次模型，模型训练设置如下表 2：

表 2：训练参数及设置

参数/设置	eLSTM	LSTM	GRU
optimizer	Adam	Adam	Adam
loss function	MSE Loss	MSE Loss	MSE Loss
initial	Xavier uniform	Xavier uniform	Xavier uniform
batch_size	256	256	256
learning_rate	0.0001	0.0001	0.0001
num_epoch	200	200	200
earlystop_epoch	20	20	20

数据来源：东北证券

4. 模型测试结果

本章对第三章构建的模型所生成的因子进行单因子测试，并对 eLSTM 生成的因子与基线模型 LSTM、GRU 生成的因子进行对比。因子测试的参数如下：


- (1) 回测区间：2017 年至 2024 年 7 月
- (2) 股票池：全 A（除北交所外）、沪深 300、中证 500、中证 1000 等股票池
- (3) 调仓频率：周频
- (4) 交易费用：不计
- (5) 分组层数：10 分组
- (6) 加权方式：等权
- (7) 基准：股票池等权基准

在以下回测结果中，使用 eLSTM 模型生成的因子直接简称为 eLSTM 因子，LSTM 因子、GRU 因子同理。

4.1. 全 A（除北交所外）


4.1.1. eLSTM 因子回测结果——全 A

图 7：eLSTM 因子 IC 测试结果——全 A



数据来源：东北证券、wind

图 8：eLSTM 因子 分层回测效果——全 A



数据来源：东北证券、wind

表 3：eLSTM 因子业绩表现——全 A（2017.1-2024.7）

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	18.24%	21.02%	28.88%	0.87	0.63
基准	-1.43%	21.98%	45.80%	-0.06	-0.03
超额	19.96%	5.30%	4.29%	3.76	4.66
多空	74.94%	11.19%	8.83%	6.70	8.49

数据来源：东北证券、wind

表 4：eLSTM 因子分年业绩表现——全 A（2017.1-2024.7）


	多头年化	基准年化	超额年化	超额夏普	超额卡玛	多空年化	多空夏普	多空卡玛
全区间	18.24%	-1.43%	19.96%	3.76	4.66	74.94%	6.70	8.49
2017	11.01%	-15.01%	30.61%	8.25	12.02	80.52%	10.62	35.95
2018	-12.29%	-29.70%	24.76%	6.07	11.48	95.18%	12.97	45.44
2019	56.71%	28.00%	22.44%	5.20	9.97	94.97%	10.32	30.63
2020	48.00%	15.52%	28.12%	4.30	6.79	67.72%	4.84	11.39
2021	44.28%	25.16%	15.27%	2.74	3.56	62.93%	5.20	13.41
2022	3.17%	-11.46%	16.53%	2.66	5.66	74.47%	5.14	8.44
2023	14.43%	5.06%	8.92%	2.10	3.69	49.02%	4.38	11.83
2024	-22.21%	-30.98%	12.71%	1.72	4.12	97.74%	8.90	30.05

数据来源：东北证券、wind

回测区间内 eLSTM 因子的周频 RankIC 均值为 7.53%，ICIR 为 1.00。多头组年化收益率 18.24%，夏普比率 0.87，卡玛比率 0.63。超额年化 19.96%，夏普比率 3.76，卡玛比率 4.66，回撤控制较好，超额最大回撤为 4.29%。各组分离度较好，多头组表现大幅领先相邻组。


4.1.2. LSTM 因子回测结果——全 A

图 9：LSTM 因子 IC 测试结果——全 A



数据来源：东北证券、wind

图 10：LSTM 因子分层回测效果——全 A



数据来源：东北证券、wind

表 5: LSTM 因子业绩表现——全 A (2017.1-2024.7)

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	11.29%	21.57%	36.41%	0.52	0.31
基准	-1.43%	21.98%	45.80%	-0.06	-0.03
超额	12.90%	5.63%	5.24%	2.29	2.46
多空	55.48%	12.05%	10.20%	4.60	5.44

数据来源：东北证券、wind

表 6: LSTM 因子分年业绩表现——全 A (2017.1-2024.7)


	多头年化	基准年化	超额年化	超额夏普	超额卡玛	多空年化	多空夏普	多空卡玛
全区间	11.29%	-1.43%	12.90%	2.29	2.46	55.48%	4.60	5.44
2017	-16.42%	-15.01%	-1.66%	-0.33	-0.41	16.13%	1.30	1.70
2018	-14.22%	-29.70%	22.03%	5.53	10.17	72.00%	10.99	29.98
2019	38.34%	28.00%	8.08%	1.52	1.61	72.43%	6.39	16.00
2020	44.79%	15.52%	25.34%	4.23	9.68	63.56%	3.96	6.78
2021	41.14%	25.16%	12.76%	1.94	2.62	35.12%	2.66	3.44
2022	3.04%	-11.46%	16.38%	2.57	6.08	71.84%	5.53	11.29
2023	10.56%	5.06%	5.23%	1.35	1.53	45.16%	4.53	10.22
2024	-15.23%	-30.98%	22.82%	2.97	4.36	114.42%	10.59	27.26

数据来源：东北证券、wind

回溯区间内 LSTM 因子的周频 RankIC 均值为 5.84%，ICIR 为 0.64。多头组年化收益率 11.29%，夏普比率 0.52，卡玛比率 0.31。超额年化 12.90%，夏普比率 2.29，卡玛比率 2.46，超额回撤控制较好，最大回撤为 5.24%。各组分离度较好，且多头组与空头组均与相邻组分离度较高。


4.1.3. GRU 因子回测结果——全 A

图 11: GRU 因子 IC 测试结果——全 A



数据来源：东北证券、wind

图 12：GRU 因子 分层回测效果——全 A



数据来源：东北证券、wind

表 7：GRU 因子业绩表现——全 A（2017.1-2024.7）

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	13.88%	20.78%	29.80%	0.67	0.47
基准	-1.43%	21.98%	45.80%	-0.06	-0.03
超额	15.53%	5.06%	4.29%	3.07	3.62
多空	62.06%	11.41%	10.51%	5.44	5.90

数据来源：东北证券、wind

表 8：GRU 因子分年业绩表现——全 A（2017.1-2024.7）

	多头年化	基准年化	超额年化	超额夏普	超额卡玛	多空年化	多空夏普	多空卡玛
全区间	13.88%	-1.43%	15.53%	3.07	3.62	62.06%	5.44	5.90
2017	3.93%	-15.01%	22.29%	6.20	11.71	66.49%	9.80	39.69
2018	-14.12%	-29.70%	22.16%	5.73	13.19	93.10%	12.48	70.62
2019	57.63%	28.00%	23.15%	4.96	8.90	86.28%	9.65	22.48
2020	30.80%	15.52%	13.23%	2.36	3.95	42.66%	2.44	4.06
2021	44.67%	25.16%	15.59%	2.95	4.69	47.60%	4.12	7.58
2022	2.28%	-11.46%	15.53%	2.55	6.89	66.99%	4.98	10.67
2023	11.31%	5.06%	5.95%	1.30	2.25	39.53%	3.89	11.56
2024	-25.90%	-30.98%	7.37%	1.14	1.72	82.17%	7.50	29.34

数据来源：东北证券、wind

回溯区间内 GRU 因子的周频 RankIC 均值为 6.76%，ICIR 为 0.86。多头组年化收益率 13.88%，夏普比率 0.67，卡玛比率 0.47。超额年化 15.53%，夏普比率 3.07，卡玛比率 3.62，超额回撤控制较好，最大回撤为 4.29%。各组分分离度较好，多头组与相邻组分分离度较高。

4.1.4. 因子回测结果对比——全 A

图 13：因子多头组对比——全 A



数据来源：东北证券、wind

表 9：因子多头组、超额业绩表现对比——全 A（2017.1-2024.7）

		年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	eLSTM	18.24%	21.02%	28.88%	0.87	0.63
	LSTM	11.29%	21.57%	36.41%	0.52	0.31
	GRU	13.88%	20.78%	29.80%	0.67	0.47
超额	eLSTM	19.96%	5.30%	4.29%	3.76	4.66
	LSTM	12.90%	5.63%	5.24%	2.29	2.46
	GRU	15.53%	5.06%	4.29%	3.07	3.62


数据来源：东北证券、wind

比较三组因子在全 A 股票池中的表现，结果表明，在相同的参数设及训练设置下得到的 eLSTM 因子各方面表现均优于 LSTM 因子和 GRU 因子。在多头组收益率方面 eLSTM 因子大幅领先；在回撤控制方面，eLSTM 因子与 GRU 因子相近，领先 LSTM 因子较多。

4.2. 沪深 300 成分股


4.2.1. eLSTM 因子回测结果——沪深 300

图 14: eLSTM 因子 IC 测试结果——沪深 300



数据来源：东北证券、wind

图 15: eLSTM 因子 分层回测效果——沪深 300



数据来源：东北证券、wind

表 10: eLSTM 因子业绩表现——沪深 300 (2017.1-2024.7)

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	18.49%	19.34%	27.12%	0.96	0.68
基准	0.85%	18.11%	33.19%	0.05	0.03
超额	17.49%	9.28%	10.84%	1.88	1.61
多空	37.76%	15.17%	24.47%	2.49	1.54

数据来源：东北证券、wind

表 11: eLSTM 因子分年业绩表现——沪深 300 (2017.1-2024.7)


	多头年化	基准年化	超额年化	超额夏普	超额卡玛	多空年化	多空夏普	多空卡玛
全区间	18.49%	0.85%	17.49%	1.88	1.61	37.76%	2.49	1.54
2017	70.40%	7.50%	58.51%	8.43	50.63	86.79%	7.67	23.49
2018	-12.74%	-26.43%	18.62%	2.14	2.54	50.86%	3.71	4.80
2019	47.73%	35.74%	8.83%	1.25	1.20	28.20%	2.34	2.12
2020	52.35%	22.28%	24.59%	2.29	3.91	46.69%	2.61	5.00
2021	4.44%	2.56%	1.83%	0.16	0.18	2.02%	0.11	0.08
2022	-6.77%	-17.65%	13.22%	1.29	2.06	45.73%	2.99	6.36
2023	-0.25%	-7.92%	8.33%	1.25	1.58	19.27%	1.21	1.54
2024	14.86%	2.24%	12.34%	1.07	1.90	49.90%	3.43	10.26

数据来源：东北证券、wind

回溯区间内 eLSTM 因子的周频 RankIC 均值为 4.74%，ICIR 为 0.41。多头组年化收益率 18.49%，夏普比率 0.96，卡玛比率 0.68。超额年化 17.49%，夏普比率 1.88，卡玛比率 1.61。多头组具有极高的分离度，但超额回撤控制不如全 A 选股表现。


4.2.2. LSTM 因子回溯结果——沪深 300

图 16: LSTM 因子 IC 测试结果——沪深 300



数据来源：东北证券、wind

图 17: LSTM 因子分层回测效果——沪深 300



数据来源：东北证券、wind

表 12: LSTM 因子业绩表现——沪深 300 (2017.1-2024.7)

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	12.40%	19.36%	26.05%	0.64	0.48
基准	0.85%	18.11%	33.19%	0.05	0.03
超额	11.45%	8.86%	9.02%	1.29	1.27
多空	24.99%	15.44%	22.47%	1.62	1.11

数据来源：东北证券、wind

表 13: LSTM 因子分年业绩表现——沪深 300 (2017.1-2024.7)


	多头年化	基准年化	超额年化	超额夏普	超额卡玛	多空年化	多空夏普	多空卡玛
全区间	12.40%	0.85%	11.45%	1.29	1.27	24.99%	1.62	1.11
2017	6.80%	7.50%	-0.65%	-0.09	-0.10	-6.29%	-0.40	-0.51
2018	-9.82%	-26.43%	22.59%	2.96	4.77	43.98%	3.41	4.20
2019	43.14%	35.74%	5.45%	0.73	0.81	30.09%	2.12	4.23
2020	61.72%	22.28%	32.25%	3.17	8.43	58.87%	3.28	5.05
2021	8.32%	2.56%	5.62%	0.48	0.65	-1.22%	-0.07	-0.05
2022	-1.34%	-17.65%	19.80%	2.03	2.20	49.24%	3.27	6.40
2023	-7.46%	-7.92%	0.50%	0.08	0.10	14.54%	1.03	1.53
2024	13.95%	2.24%	11.45%	1.24	2.30	39.83%	2.73	6.38

数据来源：东北证券、wind

回测区间内 LSTM 因子的周频 RankIC 均值为 3.10%，ICIR 为 0.23。多头组年化收益率 12.40%，夏普比率 0.64，卡玛比率 0.48。超额年化 11.45%，夏普比率 1.29，卡玛比率 1.27。多头组具有极高的分离度，但回撤控制不佳。


4.2.3. GRU 因子回测结果——沪深 300

图 18: GRU 因子 IC 测试结果——沪深 300



数据来源：东北证券、wind

图 19: GRU 因子 分层回测效果——沪深 300



数据来源：东北证券、wind

表 14: GRU 因子业绩表现——沪深 300 (2017.1-2024.7)

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	13.72%	18.67%	30.59%	0.73	0.45
基准	0.85%	18.11%	33.19%	0.05	0.03
超额	12.77%	8.59%	14.79%	1.49	0.86
多空	30.18%	14.86%	23.33%	2.03	1.29

数据来源：东北证券、wind

表 15: GRU 因子分年业绩表现——沪深 300 (2017.1-2024.7)

	多头年化	基准年化	超额年化	超额夏普	超额卡玛	多空年化	多空夏普	多空卡玛
全区间	13.72%	0.85%	12.77%	1.49	0.86	30.18%	2.03	1.29
2017	52.76%	7.50%	42.10%	6.68	15.79	56.81%	5.20	10.87
2018	-15.08%	-26.43%	15.43%	2.06	2.03	56.06%	4.44	7.25
2019	49.39%	35.74%	10.05%	1.37	1.42	37.37%	3.11	3.57
2020	37.21%	22.28%	12.21%	1.33	2.49	20.42%	1.10	1.48
2021	11.79%	2.56%	9.00%	0.84	1.31	-0.76%	-0.04	-0.03
2022	0.20%	-17.65%	21.68%	2.05	3.56	59.66%	4.03	6.35
2023	-19.81%	-7.92%	-12.91%	-1.90	-0.94	-9.31%	-0.61	-0.44
2024	19.73%	2.24%	17.10%	1.91	3.52	67.38%	5.03	12.63

数据来源：东北证券、wind

回溯区间内 GRU 因子的周频 RankIC 均值为 4.37%，ICIR 为 0.36。多头组年化收益率 13.72%，夏普比率 0.73，卡玛比率 0.45。超额年化 12.77%，夏普比率 1.49，卡玛比率 0.86。多头组具有较高的分离度，但回撤控制不佳。

4.2.4. 因子回溯结果对比——沪深 300

图 20: 因子多头组对比——沪深 300



数据来源：东北证券、wind

表 16：因子多头组业绩表现对比——沪深 300（2017.1-2024.7）

		年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头	eLSTM	18.49%	19.34%	27.12%	0.96	0.68
	LSTM	12.40%	19.36%	26.05%	0.64	0.48
	GRU	13.72%	18.67%	30.59%	0.73	0.45
超额	eLSTM	17.49%	9.28%	10.84%	1.88	1.61
	LSTM	11.45%	8.86%	9.02%	1.29	1.27
	GRU	12.77%	8.59%	14.79%	1.49	0.86


数据来源：东北证券、wind

比较三组因子在沪深 300 股票池中的表现，结果表明，eLSTM 因子各方面表现均优于 LSTM 因子和 GRU 因子。在多头组收益率方面 eLSTM 因子大幅领先；在回撤控制方面，eLSTM 因子与 LSTM 因子相近，领先 GRU 因子较多。相比于全 A 选股，因子在沪深 300 股票池中的表现主要差距在回撤控制上，一方面是因为模型在全 A 训练集中进行训练，另一方面是因为沪深 300 成分股数量相对于全 A 太少，十分组的稳定性会相较于全 A 更差。

4.3. 中证 500 成分股


4.3.1. eLSTM 因子回测结果——中证 500

图 21：eLSTM 因子 IC 测试结果——中证 500



数据来源：东北证券、wind

图 22：eLSTM 因子 分层回测效果——中证 500



数据来源：东北证券、wind

表 17：eLSTM 因子业绩表现——中证 500（2017.1-2024.7）

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	13.00%	20.27%	26.36%	0.64	0.49
基准	-0.90%	20.10%	40.35%	-0.04	-0.02
超额	14.03%	7.23%	5.81%	1.94	2.41
多空	38.19%	13.42%	9.39%	2.85	4.07

数据来源：东北证券、wind

表 18：eLSTM 因子分年业绩表现——中证 500（2017.1-2024.7）


	多头年化	基准年化	超额年化	超额夏普	超额卡玛	多空年化	多空夏普	多空卡玛
全区间	13.00%	-0.90%	14.03%	1.94	2.41	38.19%	2.85	4.07
2017	21.47%	-3.41%	25.77%	4.46	17.43	52.03%	4.47	9.92
2018	-15.44%	-31.53%	23.49%	3.82	7.06	48.20%	5.24	8.63
2019	44.46%	28.35%	12.55%	2.11	2.34	63.04%	6.01	15.02
2020	43.55%	17.45%	22.23%	2.30	4.16	40.07%	2.39	4.27
2021	39.05%	20.06%	15.82%	1.82	2.84	24.54%	1.51	3.06
2022	-10.05%	-14.49%	5.20%	0.68	0.89	40.53%	2.75	4.36
2023	-4.69%	-4.52%	-0.18%	-0.04	-0.05	12.38%	0.91	2.17
2024	-5.91%	-16.00%	12.02%	1.66	3.56	41.29%	3.64	14.62

数据来源：东北证券、wind

回测区间内 eLSTM 因子的周频 RankIC 均值为 5.60%，ICIR 为 0.58。多头组年化收益率 13.00%，夏普比率 0.64，卡玛比率 0.49。超额年化 14.03%，夏普比率 1.94，卡玛比率 2.41。多头组具有较高的分离度，超额回撤控制较好，最大回撤为 5.81%。


4.3.2. LSTM 因子回测结果——中证 500

图 23: LSTM 因子 IC 测试结果——中证 500



数据来源：东北证券、wind

图 24: LSTM 因子分层回测效果——中证 500



数据来源：东北证券、wind

表 19: LSTM 因子业绩表现——中证 500 (2017.1-2024.7)

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	7.54%	20.60%	34.40%	0.37	0.22
基准	-0.90%	20.10%	40.35%	-0.04	-0.02
超额	8.53%	7.38%	8.53%	1.16	1.00
多空	23.54%	14.33%	20.59%	1.64	1.14

数据来源：东北证券、wind

表 20: LSTM 因子分年业绩表现——中证 500 (2017.1-2024.7)


	多头年 化	基准年 化	超额年 化	超额夏 普	超额卡 玛	多空年 化	多空夏 普	多空卡 玛
全区间	7.54%	-0.90%	8.53%	1.16	1.00	23.54%	1.64	1.14
2017	-9.04%	-3.41%	-5.82%	-0.97	-0.68	-4.26%	-0.26	-0.21
2018	-20.21%	-31.53%	16.53%	2.96	8.91	34.41%	3.78	10.06
2019	37.14%	28.35%	6.85%	1.00	0.95	48.00%	3.35	6.03
2020	39.15%	17.45%	18.48%	2.02	3.34	31.55%	1.91	3.34
2021	34.72%	20.06%	12.21%	1.24	2.47	7.32%	0.42	0.56
2022	-1.92%	-14.49%	14.71%	2.05	2.50	37.12%	2.85	5.66
2023	-7.64%	-4.52%	-3.27%	-0.57	-0.40	8.45%	0.66	0.96
2024	-6.73%	-16.00%	11.04%	1.52	2.49	46.38%	3.90	8.98

数据来源：东北证券、wind

回测区间内 LSTM 因子的周频 RankIC 均值为 4.27%，ICIR 为 0.39。多头组年化收益率 7.54%，夏普比率 0.37，卡玛比率 0.22。超额年化 8.53%，夏普比率 1.16，卡玛比率 1.00。多头组具有较高的分离度，但年化收益率表现较差。


4.3.3. GRU 因子回测结果——中证 500

图 25: GRU 因子 IC 测试结果——中证 500



数据来源：东北证券、wind

图 26：GRU 因子 分层回测效果——中证 500



数据来源：东北证券、wind

表 21：GRU 因子业绩表现——中证 500（2017.1-2024.7）

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	11.94%	20.02%	30.33%	0.60	0.39
基准	-0.90%	20.10%	40.35%	-0.04	-0.02
超额	12.96%	6.58%	6.69%	1.97	1.94
多空	30.20%	13.16%	11.40%	2.30	2.65

数据来源：东北证券、wind

表 22：GRU 因子分年业绩表现——中证 500（2017.1-2024.7）

	多头年化	基准年化	超额年化	超额夏普	超额卡玛	多空年化	多空夏普	多空卡玛
全区间	11.94%	-0.90%	12.96%	1.97	1.94	30.20%	2.30	2.65
2017	19.16%	-3.41%	23.38%	4.47	15.33	55.29%	5.45	12.14
2018	-20.30%	-31.53%	16.40%	2.98	6.10	35.72%	3.78	9.68
2019	46.85%	28.35%	14.41%	2.45	3.89	46.19%	4.30	6.74
2020	35.44%	17.45%	15.32%	2.01	3.60	19.92%	1.13	1.75
2021	44.66%	20.06%	20.49%	2.48	4.85	23.02%	1.49	2.28
2022	-7.30%	-14.49%	8.41%	1.14	1.57	28.77%	2.11	3.29
2023	-8.76%	-4.52%	-4.45%	-0.83	-0.74	4.82%	0.38	0.47
2024	-1.89%	-16.00%	16.80%	2.73	5.74	53.30%	4.21	10.84

数据来源：东北证券、wind

回测区间内 GRU 因子的周频 RankIC 均值为 4.85%，ICIR 为 0.48。多头组年化收益率 11.94%，夏普比率 0.60，卡玛比率 0.39。超额年化 12.96%，夏普比率 1.97，卡玛比率 1.94。多头组具有较高的分离度。

4.3.4. 因子回测结果对比——中证 500

图 27：因子多头组对比——中证 500



数据来源：东北证券、wind

表 23：因子多头组业绩表现对比——中证 500（2017.1-2024.7）

		年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头	eLSTM	13.00%	20.27%	26.36%	0.64	0.49
	LSTM	7.54%	20.60%	34.40%	0.37	0.22
	GRU	11.94%	20.02%	30.33%	0.60	0.39
超额	eLSTM	14.03%	7.23%	5.81%	1.94	2.41
	LSTM	8.53%	7.38%	8.53%	1.16	1.00
	GRU	12.96%	6.58%	6.69%	1.97	1.94


数据来源：东北证券、wind

比较三组因子在中证 500 股票池中的表现，结果表明，eLSTM 因子各方面表现均优于 LSTM 因子和 GRU 因子，但与 GRU 因子差距不明显。在多头组收益率方面 LSTM 因子与其余两组因子差距明显；在回撤控制方面，eLSTM 因子的回撤控制相比于其他两组具有一定优势。相比于全 A 和沪深 300 选股，eLSTM 因子在中证 500 股票池中的表现主要差距在收益率方面，表明本次学习中 eLSTM 模型对于中证 500 成分股的特征在模型学习全部特征中占比较低。

4.4. 中证 1000 成分股


4.4.1. eLSTM 因子回测结果——中证 1000

图 28：eLSTM 因子 IC 测试结果——中证 1000



数据来源：东北证券、wind

图 29：eLSTM 因子 分层回测效果——中证 1000



数据来源：东北证券、wind

表 24：eLSTM 因子业绩表现——中证 1000（2017.1-2024.7）

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	12.25%	22.48%	31.69%	0.55	0.39
基准	-4.01%	22.57%	50.69%	-0.18	-0.08
超额	16.94%	6.52%	5.49%	2.60	3.09
多空	61.01%	12.69%	8.13%	4.81	7.51

数据来源：东北证券、wind

表 25：eLSTM 因子分年业绩表现——中证 1000（2017.1-2024.7）


	多头年化	基准年化	超额年化	超额夏普	超额卡玛	多空年化	多空夏普	多空卡玛
全区间	12.25%	-4.01%	16.94%	2.60	3.09	61.01%	4.81	7.51
2017	5.85%	-18.35%	29.63%	7.62	30.30	73.13%	9.33	38.42
2018	-19.76%	-33.40%	20.49%	4.12	11.19	68.19%	8.05	28.87
2019	55.83%	28.05%	21.70%	3.87	6.99	92.74%	8.68	28.01
2020	50.78%	15.07%	31.04%	3.73	7.88	76.80%	5.24	15.11
2021	37.74%	23.94%	11.14%	1.41	2.03	47.78%	3.24	7.89
2022	-3.79%	-15.69%	14.11%	1.87	3.96	78.75%	4.86	9.69
2023	2.03%	-2.44%	4.58%	0.92	1.18	33.63%	2.56	6.13
2024	-25.20%	-26.90%	2.33%	0.30	0.50	21.31%	1.69	3.97

数据来源：东北证券、wind

回溯区间内 eLSTM 因子的周频 RankIC 均值为 6.39%，ICIR 为 0.74。多头组年化收益率 12.25%，夏普比率 0.55，卡玛比率 0.39。超额年化 16.94%，夏普比率 2.60，卡玛比率 3.09。多头组具有极高的分离度，且超额回撤控制较好。


4.4.2. LSTM 因子回溯结果——中证 1000

图 30：LSTM 因子 IC 测试结果——中证 1000



数据来源：东北证券、wind

图 31: LSTM 因子分层回测效果——中证 1000



数据来源：东北证券、wind

表 26: LSTM 因子业绩表现——中证 1000 (2017.1-2024.7)

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	5.86%	22.73%	42.27%	0.26	0.14
基准	-4.01%	22.57%	50.69%	-0.18	-0.08
超额	10.28%	6.36%	7.47%	1.62	1.38
多空	45.82%	13.18%	10.39%	3.48	4.41

数据来源：东北证券、wind

表 27: LSTM 因子分年业绩表现——中证 1000 (2017.1-2024.7)


	多头年 化	基准年 化	超额年 化	超额夏 普	超额卡 玛	多空年 化	多空夏 普	多空卡 玛
全区间	5.86%	-4.01%	10.28%	1.62	1.38	45.82%	3.48	4.41
2017	-18.55%	-18.35%	-0.25%	-0.05	-0.05	23.12%	1.85	3.06
2018	-18.69%	-33.40%	22.08%	4.69	11.09	62.30%	7.96	17.61
2019	38.67%	28.05%	8.29%	1.31	1.11	62.72%	4.83	10.35
2020	44.16%	15.07%	25.28%	3.44	6.91	51.37%	3.07	6.41
2021	32.53%	23.94%	6.93%	0.83	1.01	32.50%	2.07	3.13
2022	-8.09%	-15.69%	9.01%	1.22	1.88	64.49%	4.48	12.33
2023	5.30%	-2.44%	7.93%	1.66	3.15	38.62%	3.54	7.99
2024	-23.29%	-26.90%	4.95%	0.91	1.02	46.35%	4.32	10.95

数据来源：东北证券、wind

回测区间内 LSTM 因子的周频 RankIC 均值为 5.05%，ICIR 为 0.52。多头组年化收益率 5.86%，夏普比率 0.26，卡玛比率 0.14。超额年化 10.28%，夏普比率 1.62，卡玛比率 1.38。LSTM 因子在中证 1000 股票池中的选股表现较差。


4.4.3. GRU 因子回测结果——中证 1000

图 32: GRU 因子 IC 测试结果——中证 1000



数据来源：东北证券、wind

图 33: GRU 因子 分层回测效果——中证 1000



数据来源：东北证券、wind

表 28：GRU 因子业绩表现——中证 1000（2017.1-2024.7）

	年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头组	7.13%	22.05%	36.33%	0.32	0.20
基准	-4.01%	22.57%	50.69%	-0.18	-0.08
超额	11.60%	6.10%	7.79%	1.90	1.49
多空	47.66%	12.91%	12.44%	3.69	3.83

数据来源：东北证券、wind

表 29：GRU 因子分年业绩表现——中证 1000（2017.1-2024.7）


	多头年化	基准年化	超额年化	超额夏普	超额卡玛	多空年化	多空夏普	多空卡玛
全区间	7.13%	-4.01%	11.60%	1.90	1.49	47.66%	3.69	3.83
2017	-3.75%	-18.35%	17.87%	4.71	13.69	62.74%	8.90	37.58
2018	-21.36%	-33.40%	18.07%	3.52	10.57	67.64%	7.37	24.98
2019	69.50%	28.05%	32.37%	5.50	14.06	104.03%	10.27	32.84
2020	30.35%	15.07%	13.28%	1.93	3.10	34.23%	1.85	3.02
2021	37.93%	23.94%	11.28%	1.68	2.71	36.76%	2.64	3.68
2022	-8.12%	-15.69%	8.97%	1.25	2.10	52.89%	3.40	6.09
2023	-5.62%	-2.44%	-3.26%	-0.63	-0.51	22.69%	2.01	4.81
2024	-29.64%	-26.90%	-3.74%	-0.53	-0.74	17.43%	1.37	3.62

数据来源：东北证券、wind

回溯区间内 GRU 因子的周频 RankIC 均值为 5.79%，ICIR 为 0.65。多头组年化收益率 7.13%，夏普比率 0.32，卡玛比率 0.20。超额年化 11.60%，夏普比率 1.90，卡玛比率 1.49。GRU 因子在中证 1000 股票池中的选股表现较差。

4.4.4. 因子回测结果对比——中证 1000

图 34：因子多头组对比——中证 1000



数据来源：东北证券、wind

表 30：因子多头组业绩表现对比——中证 1000（2017.1-2024.7）

		年化收益	年化波动率	最大回撤	夏普比率	卡玛比率
多头	eLSTM	12.25%	22.48%	31.69%	0.55	0.39
	LSTM	5.86%	22.73%	42.27%	0.26	0.14
	GRU	7.13%	22.05%	36.33%	0.32	0.20
超额	eLSTM	16.94%	6.52%	5.49%	2.60	3.09
	LSTM	10.28%	6.36%	7.47%	1.62	1.38
	GRU	11.60%	6.10%	7.79%	1.90	1.49

数据来源：东北证券、wind

比较三组因子在中证 1000 股票池中的表现，结果表明，eLSTM 因子各方面表现均优于 LSTM 因子和 GRU 因子。在年化收益率方面 eLSTM 因子相比于其余两组因子优势明显；在回撤控制方面，eLSTM 因子的回撤控制相比于其他两组因子也具有一定优势。相比于前面几组结果，eLSTM 因子在中证 1000 股票池中的表现差距较小，而 LSTM 因子和 GRU 因子则相比前几组结果表现出了明显的差距。这表明 eLSTM 模型相比于其他两组模型，提取出的量价序列特征的范围明显更大，在不同的股票池中的表现泛化性较好。

5. 总结

本报告从扩展的长短期记忆网络（xLSTM）得到灵感，使用指数门控代替了传统 LSTM 模型的 Sigmoid 门控，并采取措施对输出的数值稳定性和指数门的数值稳定性进行了控制，最终得到了性能更优秀的 eLSTM 模型。

本报告设计了控制变量实验，以全 A 股的日频量价数据作为训练数据集，分别以 eLSTM/LSTM/GRU 模型为基础构建了其余网络结构相同的选股因子生成模型。在训练过程中，控制模型各项超参数与训练条件相同，并在全 A、沪深 300、中证 500、中证 1000 四个股票池中对三组因子进行了单因子测试。

测试结果表明：

（1）在全 A 范围进行选股时，eLSTM 因子的多头组年化收益率以及超额年化收益率均大幅度领先 LSTM 因子和 GRU 因子，控制回撤能力也相较于另外两组因子小优。

（2）在沪深 300、中证 500、中证 1000 成分股中进行选股，即在训练集的子集中进行选股时，eLSTM 因子的表现依旧较为稳健，相比于在全 A 选股的表现退步较小。而 LSTM 因子和 GRU 因子则在不同的股票池中均表现出了相对于在全 A 选股的较大退步。这表明 eLSTM 相比于基准模型能够更完整地提取出不同类型股票的关键信息。

以上两个结论能够证明 eLSTM 模型相对于 LSTM 模型具有明显的性能提升。同时 eLSTM 模型的性能也更优于 GRU 模型。

6. 参考文献

[1] Beck M, Pöppel K, Spanring M, et al. xLSTM: Extended Long Short-Term Memory[J]. arXiv preprint arXiv:2405.04517, 2024.

7. 风险提示

本报告为模型能力探索，测试结果基于历史数据，存在模型失效风险。

研究团队简介:

王琦: 帝国理工学院数学与金融荣誉硕士，南开大学统计学学士。2021 年加入东北证券上海证券研究咨询分公司任金融工程首席分析师，研究方向为金融工程。曾任职于兴业财富资产管理有限公司，任 FOF 投资经理。

贾英: 伦敦大学学院金融数学荣誉硕士，厦门大学数学与应用数学本科。2022 年加入东北证券，研究方向为金融工程、因子选股。现任东北证券金融工程组分析师。

张栋梁: 复旦大学金融硕士，南京大学金融学本科。2022 年加入东北证券，研究方向为因子选股，现任东北证券上海证券研究咨询分公司金融工程分析师。

江雨航: 加州大学洛杉矶分校金融工程硕士，南开大学理学/经济学学士。2023 年加入东北证券，研究方向为量化固收策略，现任东北证券上海证券研究咨询分公司金融工程组研究人员。

田靖航: 北京大学金融硕士，上海财经大学经济学学士。2023 年加入东北证券，研究方向为基金研究，现任东北证券上海证券研究咨询分公司金融工程组研究人员。

刘昱亨: 北京大学计算机硕士，北京航空航天大学工学学士。2023 年加入东北证券，研究方向为机器学习量化研究，现任东北证券上海证券研究咨询分公司金融工程组研究人员。

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格，并在中国证券业协会注册登记为证券分析师。本报告遵循合规、客观、专业、审慎的制作原则，所采用数据、资料的来源合法合规，文字阐述反映了作者的真实观点，报告结论未受任何第三方的授意或影响，特此声明。

投资评级说明

股票 投资 评级 说明	买入	未来 6 个月内，股价涨幅超越市场基准 15% 以上。	投资评级中所涉及的市场基准： A 股市场以沪深 300 指数为市场基准，新三板市场以三板成指（针对协议转让标的）或三板做市指数（针对做市转让标的）为市场基准；香港市场以摩根士丹利中国指数为市场基准；美国市场以纳斯达克综合指数或标普 500 指数为市场基准。
	增持	未来 6 个月内，股价涨幅超越市场基准 5% 至 15% 之间。	
	中性	未来 6 个月内，股价涨幅介于市场基准-5% 至 5% 之间。	
	减持	未来 6 个月内，股价涨幅落后市场基准 5% 至 15% 之间。	
	卖出	未来 6 个月内，股价涨幅落后市场基准 15% 以上。	
行业 投资 评级 说明	优于大势	未来 6 个月内，行业指数的收益超越市场基准。	
	同步大势	未来 6 个月内，行业指数的收益与市场基准持平。	
	落后大势	未来 6 个月内，行业指数的收益落后于市场基准。	

重要声明

本报告由东北证券股份有限公司（以下称“本公司”）制作并仅向本公司客户发布，本公司不会因任何机构或个人接收到本报告而视其为本公司的当然客户。

本公司具有中国证监会核准的证券投资咨询业务资格。

本报告中的信息均来源于公开资料，本公司对这些信息的准确性和完整性不作任何保证。报告中的内容和意见仅反映本公司于发布本报告当日的判断，不保证所包含的内容和意见不发生变化。

本报告仅供参考，并不构成对所述证券买卖的出价或征价。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的证券买卖建议。本公司及其雇员不承诺投资者一定获利，不与投资者分享投资收益，在任何情况下，我公司及其雇员对任何人使用本报告及其内容所引发的任何直接或间接损失概不负责。

本公司或其关联机构可能会持有本报告中涉及到的公司所发行的证券头寸并进行交易，并在法律许可的情况下不进行披露；可能为这些公司提供或争取提供投资银行业务、财务顾问等相关服务。

本报告版权归本公司所有。未经本公司书面许可，任何机构和个人不得以任何形式翻版、复制、发表或引用。如征得本公司同意进行引用、刊发的，须在本公司允许的范围内使用，并注明本报告的发布人和发布日期，提示使用本报告的风险。

若本公司客户（以下称“该客户”）向第三方发送本报告，则由该客户独自为此发送行为负责。提醒通过此途径获得本报告的投资者注意，本公司不对通过此种途径获得本报告所引起的任何损失承担任何责任。

东北证券股份有限公司

网址：<http://www.nesc.cn> 电话：95360,400-600-0686 研究所公众号：dbzqyanjiusuo

地址	邮编
中国吉林省长春市生态大街 6666 号	130119
中国北京市西城区锦什坊街 28 号恒奥中心 D 座	100033
中国上海市浦东新区杨高南路 799 号	200127
中国深圳市福田区福中三路 1006 号诺德中心 34D	518038
中国广东省广州市天河区冼村街道黄埔大道西 122 号之二星辉中心 15 楼	510630

